

Cross-Lingual Zero-Shot TTS における話者性を保持した日本語音声合成の検討

発表者: I 類 メディア情報学 プログラム 学籍番号 2311093 駒月 柊平
指導教員: 高木一幸 助教

1 はじめに

近年, 短いプロンプト音声を用いて, 学習時に含まれない話者の音声を追加学習なしで合成する zero-shot text-to-speech (TTS) が研究されている [1]. さらに, プロンプト音声とは異なる言語でも話者性を保持した音声を生成する cross-lingual zero-shot TTS (以下, cross-lingual TTS) が提案されている [2]. これにより, 対象話者が実際には話していない言語でも, その話者らしい音声を合成することが期待される.

一方, cross-lingual TTS では, 対象言語として正確で自然な発話を生成することと, プロンプト音声の話者性を保持することの両方が求められる. 近年のモデルでも, 言語によって発話内容の正確性や話者類似性に差があることが報告されており [3], 特に日本語を対象とした性能とその要因を検討する余地がある.

本研究では, 対象言語を日本語とし, クロスリンガル音声合成における発話内容の正確性, 自然性, および話者類似性に与える影響を明らかにした上で, 話者性を保持した日本語音声合成の改善を目的とする. まず既存モデルの生成過程を構成要素ごとに分析し, 条件間の品質差が生じる要因を調査する. その結果に基づいて改善対象と手法を決定し, 既存モデルとの比較により有効性を検証する.

2 研究方針

CosyVoice 3[4] を主な分析対象とする. CosyVoice 3 は, テキストから音声特徴を離散トークンとして予測する LLM による text-to-token 生成部と, そのトークンと話者 embedding を条件として音響特徴へ変換する条件付き flow matching による token-to-speech 生成部, およびボコーダによる波形生成部から構成される.

本研究では, 話者性の変化がこれらのどの処理に由来するかを分析する. cross-lingual 条件ではプロンプト音声の token を LLM の入力に用いず, 話者 embedding は token-to-speech 部の条件付けにのみ用いられる. そこで通常生成に加えて, 実音声から抽出した speech token を LLM の予測の代わりに用いる条件を設け, text-to-token 部

と token-to-speech 部の影響を分けて調べる. 話者埋め込み, speech token などの条件を個別に変更する分析も行う. これらは原因候補を絞るための診断であり, 特定の改善手法の有効性を示すものではない. 改善対象を特定した後は, 対象モジュールへの LoRA (Low-Rank Adaptation) などのパラメータ効率的な追加学習, またはモデル内部に少量の学習可能な層を挿入する adapter を付加し, 学習に用いるデータセットを決定する.

3 データセット

予備分析には, 日本語と英語の音声を同一条件で比較するため, 1 名のバイリンガル話者による日英パラレル音声を収録した JECS (Japanese-English Code-Switching Speech Corpus) [5] を用いる. ただし, 収録話者が 1 名であるため, 得られた傾向の話者一般への一般化には限界がある.

複数話者における分析には, 100 名の日本語話者を収録した JVS (Japanese Versatile Speech) [6] と, 109 名の英語話者を収録した VCTK [7] を用いる.

提案手法のモデルに使用する学習データは, 分析により更新対象を決定した後, 話者数, 収録時間, 録音品質, 利用条件を考慮して選定する. 学習を行う場合は, 学習用, 検証用, 評価用の話者を分離し, zero-shot 評価の話者を学習データに含めない.

4 評価方法

CosyVoice 3 をはじめとする既存の cross-lingual TTS モデルと, 本研究で検討する改善手法を, 発話内容の正確性, 自然性, 話者類似性の 3 観点から比較評価する.

4.1 客観評価

発話内容の正確性は, 合成音声を多言語音声認識モデル Whisper large-v3 [8, 9] で文字起こしして評価する. 英語には単語誤り率 (Word Error Rate: WER), 日本語には文字誤り率 (Character Error Rate: CER) を用いる. 置換, 削除, 挿入の数をそれぞれ N_S , N_D , N_I , 正解文の単語数または文字数を N として, 誤り率を

$$\text{Error Rate} = \frac{N_S + N_D + N_I}{N} \quad (1)$$

と定義する.

話者類似性には Speaker Similarity (SIM) を用いる. 生成モデルの条件付けには使用されていない外部の話者照合モデル WeSpeaker [10] により, プロンプト音声と合成音声から話者埋め込み e_p と e_s を抽出し,

$$\text{SIM} = \frac{e_p^T e_s}{\|e_p\|_2 \|e_s\|_2} \quad (2)$$

によりコサイン類似度を求める. SIM は, 当該埋め込み空間における類似性の代理指標である. 話者照合モデルの言語依存性を確認するため, 同一話者の実音声間についても同一言語・異言語の SIM を算出する. 自然性の自動評価には, 音声から知覚品質に関する Mean Opinion Score (MOS) を推定する UTMOS[11] を用いる.

4.2 主観評価

客観指標のみでは知覚的な自然性や話者らしさを十分に評価できないため, 聴取実験を行う. 評価者数は 10~20 名以上を目安として確保する. 自然性は MOS を用い, 「非常に不自然」から「非常に自然」までの 5 段階で評価する. 話者類似性は Similarity Mean Opinion Score (SMOS) を用い, 参照音声と合成音声を提示して, 「全く似ていない」から「非常に似ている」までの 5 段階で評価する. 日本語音声については, 日本語母語話者を評価者とする.

改善手法と基盤モデルの差を直接比較する必要がある場合は, 提示順を無作為化した比較評価を行う. 自然性など評価軸を一つずつ提示し, 基盤モデルに対する改善手法の相対評価を -3 から +3 の 7 段階で求める.

5 おわりに

本研究では, cross-lingual TTS における話者性を保持した日本語音声合成を目的とし, 既存モデルの生成過程を構成要素ごとに分析する. 現在は, プロンプト言語と生成言語を分けた通常生成, 実音声の speech token を用いた生成, および話者条件の変更実験により, 改善対象を選定するための検討を進めている.

今後は, 複数話者を対象として分析結果の再現性を確認し, その結果に基づいて改善対象, 改善手法, および学習データを決定する. その後, 提案手法について, 発話内容の正確性, 自然性, および話者類似性を客観評価と主観評価の両面から検証する.

参考文献

[1] Chengyi Wang, et al. Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers. *arXiv preprint*

arXiv:2301.02111, 2023.

[2] Ziqiang Zhang, et al. Speak Foreign Languages with Your Own Voice: Cross-Lingual Neural Codec Language Modeling. *arXiv preprint arXiv:2303.03926*, 2023.

[3] Rixi Xu, et al. X-Voice: Enabling Everyone to Speak 30 Languages via Zero-Shot Cross-Lingual Voice Cloning. *arXiv preprint arXiv:2605.05611*, 2026.

[4] Zhihao Du, et al. CosyVoice 3: Towards In-the-wild Speech Generation via Scaling-up and Post-training. *arXiv preprint arXiv:2505.17589*, 2025.

[5] Shinnosuke Takamichi, et al. JECS: Japanese-English Code-Switching Speech Corpus. https://sites.google.com/site/shinnosuketakamichi/research-topics/jecs_corpus. Accessed: 2026-09-04.

[6] Shinnosuke Takamichi, et al. JVS Corpus: Free Japanese Multi-Speaker Voice Corpus. *arXiv preprint arXiv:1908.06248*, 2019.

[7] Christophe Veaux, et al. CSTR VCTK Corpus: English Multi-Speaker Corpus for CSTR Voice Cloning Toolkit. University of Edinburgh, The Centre for Speech Technology Research, 2019.

[8] Alec Radford, et al. Robust Speech Recognition via Large-Scale Weak Supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pp. 28492–28518, 2023.

[9] OpenAI. Whisper large-v3 Release. <https://github.com/openai/whisper/discussions/1762>, 2023. Accessed: 2026-09-04.

[10] Hongji Wang, et al. WeSpeaker: A Research and Production Oriented Speaker Embedding Learning Toolkit. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing*, 2023.

[11] Takaaki Saeki, et al. UTMOS: UTokyo-SaruLab System for VoiceMOS Challenge 2022. In *Proceedings of Interspeech*, pp. 4521–4525, 2022.