

多言語 zero-shot TTS における話者性を保持した日本語音声合成の検討

発表者: I 類 メディア情報学 プログラム 学籍番号 2311093 駒月 柊平
指導教員: 高木一幸 助教

1 はじめに

近年, 短いプロンプト音声を用いて, 学習時に含まれない話者の音声を追加学習なしで合成する zero-shot text-to-speech (TTS) が研究されている [1]. さらに, プロンプト音声とは異なる言語でも話者性を保持した音声を生成する cross-lingual TTS が提案されている [2]. これにより, 対象話者が実際には話していない言語でも, その話者らしい音声を合成することが期待される.

一方, cross-lingual TTS では, 対象言語として正確で自然な発話を生成することと, プロンプト音声の話者性を保持することの両方が求められる. 近年のモデルでも, 言語によって発話内容や話者類似性に差があることが報告されており [3], 特に日本語を対象とした性能とその要因を検討する余地がある.

本研究では, 多言語 zero-shot TTS における日本語を対象言語とし, プロンプト言語の違いが発話内容, 自然性, および話者類似性に与える影響を明らかにした上で, 話者性を保持した日本語音声合成の改善を目的とする. まず既存モデルの生成過程を構成要素ごとに分析し, 条件間の品質差が生じる要因を調査する. その結果に基づいて改善対象と手法を決定し, 既存モデルとの比較により有効性を検証する.

2 研究方針

現段階では, LLM による text-to-token 生成と条件付き flow matching による token-to-speech 生成から構成される CosyVoice 3 [4] を主な分析対象とする. 話者性の変化がどの処理に由来するかを切り分けるため, プロンプト言語と生成言語を独立に変えた条件を比較する. 同一言語条件として日本語から日本語および英語から英語, cross-lingual 条件として英語から日本語および日本語から英語を扱い, 同一の話者, 入力文, 推論条件を可能な限り揃える.

また, 通常生成に加えて, 実音声から抽出した speech token を LLM の予測の代わりに用いる条件を設け, text-to-token 部と token-to-speech 部の影響を分けて調べる. 話者埋め込み, プロンプト音響特徴, speech token などの条

件を個別に変更する分析も行う. これらは原因候補を絞るための診断であり, 特定の改善手法の有効性を示すものではない. 改善対象を特定した後に, 対象モジュールの追加学習, adapter, または入力表現の変更などから, 計算資源と必要データに適した方法を選定する.

3 使用データ

予備分析には, 日本語と英語の音声を同一条件で比較するため, 1 名のバイリンガル話者による日英パラレル音声を収録した JECS [5] を用いる. JECS はプロンプト言語以外の話者差を抑えられる一方, 1 話者のみであるため, 得られた傾向を話者一般へ適用することはできない.

複数話者における分析には, 100 名の日本語話者を収録した JVS [6] と, 109 名の英語話者を収録した VCTK [7] を用いる. これらは speech token と話者条件の関係を各言語内で調べるために用いるが, 同一人物の日英音声ではないため, コーパス間の SIM の絶対値を言語差として比較しない.

最終的な改善手法の学習データは, 分析により更新対象を決定した後, 話者数, 収録時間, 録音品質, 利用条件を考慮して選定する. 学習を行う場合は, 学習用, 検証用, 評価用の話者を分離し, zero-shot 評価の話者を学習データに含めない.

4 評価方法

各生成条件および今後検討する改善手法を, 発話内容の正確性, 自然性, 話者類似性の 3 観点から評価する.

4.1 客観評価

発話内容の正確性は, 合成音声を多言語音声認識モデル Whisper [8] の large-v3 [9] で文字起こしして評価する. 英語には単語誤り率 (Word Error Rate: WER), 日本語には文字誤り率 (Character Error Rate: CER) を用いる. 置換, 削除, 挿入の数をそれぞれ N_S , N_D , N_I , 正解文の単語数または文字数を N として, 誤り率を

$$\text{Error Rate} = \frac{N_S + N_D + N_I}{N} \quad (1)$$

と定義する.

話者類似性には Speaker Similarity (SIM) を用いる。生成モデルの条件付けには使用されていない外部の話者照合モデル WeSpeaker [10] により、プロンプト音声と合成音声から話者埋め込み e_p と e_s を抽出し、

$$\text{SIM} = \frac{e_p^T e_s}{\|e_p\|_2 \|e_s\|_2} \quad (2)$$

によりコサイン類似度を求める。SIM は、当該埋め込み空間における類似性の代理指標である。話者照合モデルの言語依存性を確認するため、同一話者の実音声間についても同一言語・異言語の SIM を算出する。自然性の自動評価には、知覚品質に関する MOS を予測する UTMOS[11] を用いる。

4.2 主観評価

客観指標のみでは知覚的な自然性や話者らしさを十分に評価できないため、聴取実験を行う。自然性は Mean Opinion Score (MOS) を用い、「非常に不自然」から「非常に自然」までの 5 段階で評価する。話者類似性は Similarity Mean Opinion Score (SMOS) を用い、参照音声と合成音声を提示して、「全く似ていない」から「非常に似ている」までの 5 段階で評価する。日本語音声については、日本語母語話者を評価者とし、発音およびアクセントの自然性も話者類似性とは分けて評価する。

改善手法と基盤モデルの小さな差を直接比較する必要がある場合は、提示順を無作為化した比較評価を行う。自然性など評価軸を一つずつ提示し、基盤モデルに対する改善手法の相対評価を -3 から +3 の 7 段階で求める。

5 おわりに

本研究では、cross-lingual TTS における話者性を保持した日本語音声合成を目的とし、既存モデルの生成過程を構成要素ごとに分析する。現在は、プロンプト言語と生成言語を分けた通常生成、実音声の speech token を用いた生成、および話者条件の変更実験により、改善対象を選定するための検討を進めている。今後は、複数話者と複数の聴取評価者を用いて観測の再現性を確認し、その結果に基づいて改善手法と学習データを決定する。その後、内容一致、自然性、話者類似性を客観評価と主観評価の両面から検証する。

参考文献

[1] Chengyi Wang, et al. Neural codec language models are zero-shot text to speech synthesizers. *arXiv preprint arXiv:2301.02111*, 2023.

[2] Ziqiang Zhang, et al. Speak foreign languages with your own voice: Cross-lingual neural codec language modeling. *arXiv preprint arXiv:2303.03926*, 2023.

[3] Rixi Xu, Qingyu Liu, Haitao Li, et al. X-Voice: Enabling everyone to speak 30 languages via zero-shot cross-lingual voice cloning. *arXiv preprint arXiv:2605.05611*, 2026.

[4] Zhihao Du, Changfeng Gao, Yuxuan Wang, et al. CosyVoice 3: Towards in-the-wild speech generation via scaling-up and post-training. *arXiv preprint arXiv:2505.17589*, 2025.

[5] Shinnosuke Takamichi, Yoshifumi Nakano, Ai Morimatsu, Takaaki Saeki, and Hiroshi Saruwatari. JECS: Japanese-english code-switching speech corpus. https://sites.google.com/site/shinnosuketakamichi/research-topics/jecs_corpus. Accessed: 2026-09-04.

[6] Shinnosuke Takamichi, Kentaro Mitsui, Yuki Saito, Tomoki Koriyama, Naoko Tanji, and Hiroshi Saruwatari. JVS corpus: Free japanese multi-speaker voice corpus. *arXiv preprint arXiv:1908.06248*, 2019.

[7] Christophe Veaux, Junichi Yamagishi, and Kirsten MacDonal. CSTR VCTK corpus: English multi-speaker corpus for CSTR voice cloning toolkit. University of Edinburgh, The Centre for Speech Technology Research, 2019.

[8] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pp. 28492–28518, 2023.

[9] OpenAI. Whisper large-v3 release. <https://github.com/openai/whisper/discussions/1762>, 2023. Accessed: 2026-09-04.

[10] Hongji Wang, Chengdong Liang, Shuai Wang, et al. WeSpeaker: A research and production oriented speaker embedding learning toolkit. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing*, 2023.

[11] Takaaki Saeki, Detai Xin, Wataru Nakata, Tomoki Koriyama, Shinnosuke Takamichi, and Hiroshi Saruwatari. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022. In *Proceedings of Interspeech*, pp. 4521–4525, 2022.