

卒論予稿フォーマット

発表者: I 類 メディア情報学 プログラム 学籍番号 2311093 駒月 柊平
指導教員: 高木一幸 助教

1 はじめに

「はじめに」の部分はモデルの導入部、背景などを中心に自分の研究の位置づけを書いて下さい。必要であれば、引用文献を使って自分の立ち位置を記述することが重要です [3]。研究内容をいきなりモデルや実験の説明から始めてはいけません。研究目的を達成するために、どのようなアプローチをとるのか、これから述べる方法で、何が何処まで明らかに (あるいは期待) 出来るかなどを書く必要があるでしょう。

2 提案手法

あ

3 データセット

あ

4 評価方法

提案手法の有効性を検証するため、発話内容の正確性、音声の自然性、およびプロンプト音声に対する話者類似性の 3 つの観点から評価を行う。比較対象には追加学習前のモデルを用い、同一のプロンプト音声と入力テキストから生成した音声を評価する。

4.1 客観評価

発話内容の正確性は、合成音声を多言語音声認識モデル Whisper large-v3[1] によって文字起こしし、入力テキストを正解文として評価する。英語音声には単語誤り率 (Word Error Rate: WER)、日本語音声には文字誤り率 (Character Error Rate: CER) を用いる。WER および CER は、置換数を N_S 、削除数を N_D 、挿入数を N_I 、正解文の単語数または文字数を N として、次式により算出する。

$$\text{Error Rate} = \frac{N_S + N_D + N_I}{N}. \quad (1)$$

値が小さいほど、入力テキストの内容が正確に発話されていることを示す。

話者類似性の評価には Speaker Similarity (SIM) を用いる。プロンプト音声と合成音声から話者埋め込み e_p および

e_s を抽出し、両者のコサイン類似度を次式により求める。

$$\text{SIM} = \frac{e_p^T e_s}{\|e_p\|_2 \|e_s\|_2}. \quad (2)$$

値が大きいほど、合成音声にプロンプト話者の特徴が保持されていることを示す。また、合成音声の自然性および音質を自動的に推定する指標として UTMOS[2] を用いる。

4.2 主観評価

客観指標のみでは知覚的な自然性や話者らしさを十分に評価できないため、聴取実験による主観評価を行う。音声の自然性は Mean Opinion Score (MOS) を用い、「非常に不自然」から「非常に自然」までの 5 段階で評価する。話者類似性は Speaker Mean Opinion Score (SMOS) を用い、プロンプト音声と合成音声を提示して、「全く似ていない」から「非常に似ている」までの 5 段階で評価する。

さらに、追加学習前後の音声を直接比較する場合には Comparative Mean Opinion Score (CMOS) を用いる。同一条件で生成した 2 つの音声を提示順序を無作為化して提示し、提案手法の音声と比較対象よりどの程度優れているかを -3 から +3 の 7 段階で評価する。MOS および UTMOS により自然性、SIM および SMOS により話者類似性、WER または CER により発話内容の正確性をそれぞれ評価し、これらを総合して提案手法の有効性を検証する。

5 まとめ

最後は簡潔に研究成果をまとめて下さい。将来の課題などもあれば書いても良いですが、あまり課題を書きすぎると逆効果になりますのでほどほどにしておきましょう。

また、引用文献はキチンと入れましょう [3]。引用は、先人に対するリスペクトなので、よほど独立性が高い研究でない限り必要となります。

参考文献

- [1] Alec Radford, et al. Robust speech recognition via large-scale weak supervision. In *Proceedings of ICML*, pp. 28492–28518, 2023.
- [2] Takaaki Saeki, et al. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022. In *Proceedings of Interspeech*, pp. 4521–4525, 2022.

[3] 木下是雄. 理科系の作文技術. 中公新書 624. 中央公論新社,
1981.