

## 卒論予稿フォーマット

発表者: I 類 メディア情報学 プログラム 学籍番号 2311093 駒月 柊平  
指導教員: 高木一幸 助教

### 1 はじめに

近年、短いプロンプト音声を用いて、学習時に含まれない話者の音声を追加学習なしで合成する zero-shot TTS が研究されている [1]。さらに、zero-shot TTS を多言語に拡張し、プロンプト音声とは異なる言語でも話者性を保持した音声を生成する cross-lingual TTS が提案されている [2]。これにより、対象話者が実際には話していない言語についても、その話者らしい音声を合成することが期待される。

一方、予備的に既存モデルの合成音声を聴取したところ、英語を生成する場合と比較して、日本語を生成する場合には声質が機械的または平均的に感じられ、プロンプト音声の話者らしさが十分に保持されない傾向が見られた。このことから、cross-lingual TTS では、生成言語によって話者性の保持性能が異なる可能性がある。

そこで本研究では、プロンプト音声を持つ話者性を保持しながら、異なる言語、特に日本語の音声を生成できる cross-lingual TTS の実現を目的とする。X-Voice または CosyVoice3 を基盤モデルの候補とし、日本語を含む音声データを用いた追加学習や Low-Rank Adaptation (LoRA) の適用を検討する。追加学習前後のモデルを比較し、発話内容の正確性、音声の自然性、およびプロンプト音声に対する話者類似性の観点から有効性を検証する。

### 2 提案手法

あ

### 3 データセット

あ

### 4 評価方法

提案手法の有効性を検証するため、発話内容の正確性、音声の自然性、およびプロンプト音声に対する話者類似性の 3 つの観点から評価を行う。比較対象には追加学習前のモデルを用い、同一のプロンプト音声と入力テキストから生成した音声を評価する。

#### 4.1 客観評価

発話内容の正確性は、合成音声を多言語音声認識モデル Whisper large-v3[3] によって文字起こしし、入力テキストを正解文として評価する。英語音声には単語誤り率 (Word Error Rate: WER)、日本語音声には文字誤り率 (Character Error Rate: CER) を用いる。WER および CER は、置換数を  $N_S$ 、削除数を  $N_D$ 、挿入数を  $N_I$ 、正解文の単語数または文字数を  $N$  として、次式により算出する。

$$\text{Error Rate} = \frac{N_S + N_D + N_I}{N}. \quad (1)$$

値が小さいほど、入力テキストの内容が正確に発話されていることを示す。

話者類似性の評価には Speaker Similarity (SIM) を用いる。プロンプト音声と合成音声から話者埋め込み  $e_p$  および  $e_s$  を抽出し、両者のコサイン類似度を次式により求める。

$$\text{SIM} = \frac{e_p^T e_s}{\|e_p\|_2 \|e_s\|_2}. \quad (2)$$

値が大きいほど、合成音声にプロンプト話者の特徴が保持されていることを示す。また、合成音声の自然性および音質を自動的に推定する指標として UTMOS[4] を用いる。

#### 4.2 主観評価

客観指標のみでは知覚的な自然性や話者らしさを十分に評価できないため、聴取実験による主観評価を行う。音声の自然性は Mean Opinion Score (MOS) を用い、「非常に不自然」から「非常に自然」までの 5 段階で評価する。話者類似性は Speaker Mean Opinion Score (SMOS) を用い、プロンプト音声と合成音声を提示して、「全く似ていない」から「非常に似ている」までの 5 段階で評価する。

さらに、追加学習前後の音声を直接比較する場合には Comparative Mean Opinion Score (CMOS) を用いる。同一条件で生成した 2 つの音声を提示順序を無作為化して提示し、提案手法の音声と比較対象よりどの程度優れているかを -3 から +3 の 7 段階で評価する。MOS および UTMOS により自然性、SIM および SMOS により話者類似性、WER または CER により発話内容の正確性をそれぞれ評価し、これらを総合して提案手法の有効性を検証する。

## 5 まとめ

本研究では、cross-lingual TTS において、合成音声の言語が異なる場合にもプロンプト音声の話者性を保持することを目的とする。特に、日本語の合成音声で話者らしさが低下するという問題に対して、既存の多言語 TTS モデルへの追加学習や LoRA の適用による改善を検討する。

今後は、X-Voice および CosyVoice3 の予備評価を行い、話者類似性、日本語音声の自然性、追加学習の実現可能性を踏まえて基盤モデルを決定する。その後、使用するデータセットと学習条件を整備し、追加学習前後のモデルから同一条件で音声を生成する。WER または CER, SIM, UTMOS による客観評価と、MOS, SMOS, CMOS による主観評価を行い、発話内容の正確性を維持しながら、日本語音声の自然性および話者類似性を改善できるかを検証する。

## 参考文献

- [1] Chengyi Wang, et al. Neural codec language models are zero-shot text to speech synthesizers. *arXiv preprint arXiv:2301.02111*, 2023.
- [2] Ziqiang Zhang, et al. Speak foreign languages with your own voice: Cross-lingual neural codec language modeling. *arXiv preprint arXiv:2303.03926*, 2023.
- [3] Alec Radford, et al. Robust speech recognition via large-scale weak supervision. In *Proceedings of ICML*, pp. 28492–28518, 2023.
- [4] Takaaki Saeki, et al. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022. In *Proceedings of Interspeech*, pp. 4521–4525, 2022.