

卒論予稿フォーマット

発表者: I 類 メディア情報学 プログラム 学籍番号 2311093 駒月 柊平
指導教員: 高木一幸 助教

1 はじめに

近年, 短いプロンプト音声を用いて, 学習時に含まれない話者の音声を追加学習なしで合成する zero-shot TTS が研究されている [1]. さらに, zero-shot TTS を多言語に拡張し, プロンプト音声とは異なる言語でも話者性を保持した音声を生成する cross-lingual TTS が提案されている [2]. これにより, 対象話者が実際には話していない言語についても, その話者らしい音声を合成することが期待される.

一方, 多言語 zero-shot TTS では, 学習に用いられた言語や音声量の違いにより, 生成言語ごとに発話内容の正確性, 自然性, および話者性の保持性能が異なる可能性がある.

(TODO: ここに追加で何か書くかも. どう問題があったのか. 予備実験とか.)

そこで本研究では, 多言語 zero-shot TTS における日本語を対象言語とし, プロンプト音声の言語によらず, 発話内容が正確で, 自然かつ対象話者らしい日本語音声を合成することを目的とする. 既存の多言語 TTS モデルに対して日本語音声データを用いた追加学習を行い, 追加学習前後のモデルを比較する. さらに, 日本語への適応によって既存の他言語合成能力が低下しないかを確認する.

2 提案手法

本研究では, 既存の多言語 zero-shot TTS モデルを基盤とし, 日本語テキストと音声の対を用いてモデルを追加学習する. 入力として対象話者の短いプロンプト音声と日本語テキストを与え, プロンプト音声の話者性を保持した日本語音声を生成する.

追加学習では, 基盤モデルが持つ zero-shot 話者生成能力を維持しながら, 日本語の発音および韻律に関する部分を適応する.

(TODO: 具体的なやり方は後で書く. 要検討.)

比較対象には追加学習前の基盤モデルを用いる. 同一のプロンプト音声および入力テキストから追加学習前後の音声を生成し, (後で書く)

3 データセット

日本語への追加学習には, 複数話者による日本語音声と発話テキストの対を用いる. 特定の学習話者へ声質が偏ることを避けるため, 単一話者データのみではなく, 多話者データを中心に構成する. 音声は基盤モデルの入力条件に合わせてサンプリング周波数を統一し, 発話前後の過度な無音を除去する. また, 数字, 英字, 記号などの表記揺れを抑えるため, 発話テキストに正規化処理を施す.

(TODO: 具体的などういうデータセットを使うかは後で書く. 要検討. ATR MANY も候補.)

追加学習用, 検証用, および評価用のデータは分離する. 特に zero-shot 話者生成を評価するため, 評価に用いる話者は追加学習用データに含まれる話者と重複しないようにする. 評価用データでは, 日本語および英語のプロンプト音声と,

4 評価方法

提案手法の有効性を検証するため, 発話内容の正確性, 音声の自然性, およびプロンプト音声に対する話者類似性の 3 つの観点から評価を行う. 比較対象には追加学習前のモデルを用い, 同一のプロンプト音声と入力テキストから生成した音声を評価する.

4.1 客観評価

発話内容の正確性は, 合成音声を多言語音声認識モデル Whisper [3] の large-v3[4] によって文字起こしし, 入力テキストを正解文として評価する. 英語音声には単語誤り率 (Word Error Rate: WER), 日本語音声には文字誤り率 (Character Error Rate: CER) を用いる. WER および CER は, 置換数を N_S , 削除数を N_D , 挿入数を N_I , 正解文の単語数または文字数を N として, 次式により算出する.

$$\text{Error Rate} = \frac{N_S + N_D + N_I}{N}. \quad (1)$$

値が小さいほど, 入力テキストの内容が正確に発話されていることを示す.

話者類似性の評価には Speaker Similarity (SIM) を用いる. プロンプト音声と合成音声から話者埋め込み e_p およ

び e_s を抽出し、両者のコサイン類似度を求める。値が大きいほど、合成音声にプロンプト話者の特徴が保持されていることを示す。また、合成音声の自然性および音質を自動的に推定する指標として UTMOS[5] を用いる。

4.2 主観評価

客観指標のみでは知覚的な自然性や話者らしさを十分に評価できないため、聴取実験による主観評価を行う。音声の自然性は Mean Opinion Score (MOS) を用い、「非常に不自然」から「非常に自然」までの 5 段階で評価する。話者類似性は Speaker Mean Opinion Score (SMOS) を用い、プロンプト音声と合成音声を提示して、「全く似ていない」から「非常に似ている」までの 5 段階で評価する。

さらに、追加学習前後の音声を直接比較する場合には Comparative Mean Opinion Score (CMOS) を用いる。同一条件で生成した 2 つの音声を提示順序を無作為化して提示し、提案手法の音声と比較対象よりどの程度優れているかを -3 から $+3$ の 7 段階で評価する。MOS および UTMOS により自然性、SIM および SMOS により話者類似性、WER または CER により発話内容の正確性をそれぞれ評価し、これらを総合して提案手法の有効性を検証する。

5 おわりに

本研究では、cross-lingual TTS において、合成音声の言語が異なる場合にもプロンプト音声の話者性を保持することを目的とする。特に日本語を対象言語とし、既存の多言語 TTS モデルへの追加学習や LoRA の適用により、発話内容の正確性と話者性を維持しながら、日本語合成音声の自然性を改善する方法を検討する。

今後は、基盤モデルと日本語音声データを決定し、既存モデルの言語およびプロンプト言語ごとの性能を予備評価する。その結果に基づいて更新対象を決定し、追加学習前後のモデルを客観評価および聴取実験により比較する。

参考文献

- [1] Chengyi Wang, et al. Neural codec language models are zero-shot text to speech synthesizers. *arXiv preprint arXiv:2301.02111*, 2023.
- [2] Ziqiang Zhang, et al. Speak foreign languages with your own voice: Cross-lingual neural codec language modeling. *arXiv preprint arXiv:2303.03926*, 2023.
- [3] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pp. 28492–28518, 2023.
- [4] OpenAI. Whisper large-v3 release. <https://github.com/openai/whisper/discussions/1762>, 2023. Accessed: 2026-08-28.
- [5] Takaaki Saeki, et al. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022. In *Proceedings of Interspeech*, pp. 4521–4525, 2022.