

声質表現を制御する Transformer ベースのテキスト音声合成システム

発表者: I 類 メディア情報学プログラム 学籍番号 2110048 伊佐早佳月
指導教員: 高木一幸 助教

1 はじめに

近年、画像生成系の DALL-E[1] や自然言語系の Chat-GPT[2] でも Transformer[3] が利用されている。これらのモデルは、並列処理に優れた Transformer を活用し、テキストベースで生成を制御している。テキスト制御が用いられる理由として、生成物の柔軟性と汎用性に加え、誰でも使用できる言語を入力として扱うことで、直感的にユーザーの意図に沿った生成が可能になることが挙げられる。しかし、音声合成分野ではテキストと声質で対多マッピング問題が生じることが知られており、声質をテキストで制御する例は非常に少ない。例えば「若い男性が優しい口調で喋っている」という声質を指定した場合でも、人によって想像する声は異なってくるだろう。声質をテキストベースで制御することについて、Prompt-TTS[4] をはじめとした先行研究は複数あるものの、それらはいずれも英語での研究で、日本語での研究は無い。先行研究では、話者情報と韻律情報をまとめて「声質制御文」として処理していたが、これらを分離可能と考え、生成過程も別々に処理できるようなシステムを開発することを目指した。この研究により、言葉の微細なニュアンスまで伝えられる、自然で聞き取りやすい合成音声の実現できると考えた。本研究の目的は、文章により直感的に声質の話者情報と韻律情報を制御する日本語音声合成システムを開発することである。

2 提案システム

2.1 システムの概要

提案システムは主に Content Encoder、Style Encoder、Speech Decoder に分かれている。機械学習部分では Transformer ブロックを採用しており、音声合成全体は一貫学習を行う Encoder-Decoder モデルである (図 1)。このモデルは、発話内容文と声質表現文を入力とし、音声波形を出力する。学習には、発話内容文、声質制御文、音声が必要であり、音素列変換モデル、日本語 BERT[5]、WaveNet-Vocoder[6] といった既存の学習済みモデルを使用する。




図 1 音声合成システムの概要

2.2 Content Encoder

Content Encoder は発話内容文を入力とし、それを音素列に変換し、Transformer ブロックに通すことで中間表現に変換するような seq2seq モデルである。Transformer ブロックの前には Positional Encoding を行い、文字列に位置情報を付加することで語順を学習できるようにする。幅広い声質の学習に対応させるため、Content Encoder の最後に FastSpeech2[7] に倣い、音声の継続時間、ピッチ、エネルギーを予測する Variance Adaptor を設置した。

2.3 Style Encoder

Style Encoder は声質制御文を入力とし、話者埋め込みと韻律埋め込みを出力とする機構である。まず辞書を基に声質制御文を非言語情報部分とパラ言語情報部分に分離し、

それぞれに対して以下の手順を実行する。学習済み日本語 BERT モデルを用いて文を固定長のベクトル表現へと変換し、埋め込みベクトルを予測する。一対多マッピングに対処するため、及び、言語だけではカバーできない多彩な声質を表現するため、それぞれの埋め込みベクトルから話者埋め込みと韻律埋め込みを予測するモデルを作成する。

話者埋め込みは発話全体に対して話者の情報を与えるベクトル表現であり、基本周波数や振幅の大きさなどの情報が該当する。一方、韻律埋め込みは時系列データであり、表現が難しい。openSMILE で得られるさまざまな特徴ベクトルから韻律を反映するベクトル表現を識別的トレーニングによって得る。

2.4 Speech Decoder

Speech Decoder は、Content Encoder の出力に Positional Encoding を適用し、Style Encoder の出力を先頭に付加して入力とする。これらのベクトルからメルスペクトログラムを生成し、学習済みの日本語ボコーダに入力して音声波形を生成する。

3 データセット

発話内容文と声質表現文と音声のペアデータセットの日本語声質表現文音声ペアコーパス Coco-Nut[8] では合計 8 時間にわたる 7664 発話を備えているが、先行研究の promptTTS では学習に 26588 発話とテストに 1305 発話、promptTTS++[9] では約 585 時間のデータが用いられており、それらと比較して学習データの不足が考えられる。このデータ不足を改善するため、Coco-Nut に加えて研究に用いることのできるデータを収集した。

3.1 データセットの構成

データセットは、様々な話者による発話を含む「音声」、その音声に対応するテキストデータとしての「読み上げ文」、話者の声質や感情、抑揚などの特徴を詳細に記述した「声質表現文」によって構成される。

3.2 データセットの要件

本研究では、Coco-Nut[8] に加えて機械学習に用いるデータを作成するため、データの要件は Coco-Nut に従うものとした。まず、特徴的な声を対象として、TTS システムに利用できるほど高品質な音声データであること。音声には適切な声質プロンプトを付与し、男女比はおおよそ 1 対 1 となるようにバランスを取ること。ただし、幼児や高齢者の音声は学習に適さない可能性があり収集対象外とした。

3.3 データ収集

データの収集は以下の手順で行なった。(1) YouTube 上から、声質表現を含んだ検索ワードでの再生回数順で上位から順に、特徴的な声を収集した。(2) 収集した音声データを音声区間ごとに区切り、その区間の背景音や BGM などを取り除き音声のみを分離して取り出した。この際、Coco-Nut に倣い Demucs を用いた。(3) 声質制御文は検索ワードや動画コメント欄から生成した。

4 おわりに

本研究では、音声合成の新たなアプローチとして、プロンプトベースで話者情報と非言語情報を制御することを試みる。現時点での課題として、声質表現文を収集することの難易度が高いことが挙げられる。また、韻律特徴量に何を用いるかを検討する必要がある。また、話者特徴が発話全体に対してのものである一方、韻律特徴は時系列データであるためこの 2 つをどのように統合するかも課題である。実験の評価方法として、現時点では、MOS (Mean Opinion Score) を使用することを考えている。

これまでに実施したことは、音声データを効率的に収集するためのプログラムの作成である。今後、データのさらなる収集に加え、話者埋め込みおよび韻律埋め込みの予測器を作成することが必要である。これらの課題を解決し、より精度の高い音声合成システムの実現を目指す。

参考文献

- [1] Aditya Ramesh, et al. “Zero-Shot Text-to-Image Generation,” arXiv:2102.12092, 2021.
- [2] OpenAI “GPT-4 Technical Report,” 2024.
- [3] Ashish Vaswani, et al. “Attention Is All You Need,” Neural Information Processing Systems, pp. 6000-6010. arXiv:1706.03762, 2023.
- [4] Zhifang Guo, et al. “PromptTTS: Controllable Text-to-Speech with Text Descriptions,” arXiv:2211.12171, 2022.
- [5] Jacob Devlin, et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” arXiv:1810.04805, 2018.
- [6] Aaron van den Oord, et al. “WaveNet: A Generative Model for Raw Audio,” arXiv:1609.03499, 2016.
- [7] Yi Ren, et al. “FastSpeech 2: Fast and High-Quality End-to-End Text to Speech,” arXiv:2006.04558, 2022.
- [8] 渡邊 亞椰 他 “Coco-Nut: 自由記述文による声質制御に向けた多話者音声・声質自由記述ペアデータセット,” 2023.
- [9] Reo Shimizu, et al. “PromptTTS++: Controlling Speaker Identity in Prompt-based Text-to-Speech using Natural Language Descriptions,” arXiv:2309.08140, 2023.