

メロディを考慮した J-POP 楽曲の歌詞認識

発表者: I 類メディア情報学プログラム 学籍番号 2010210 瓦林悠飛
指導教員: 高木一幸 助教

1 はじめに

音声認識の歴史は長く、数多くの研究により現在では完璧に近い認識性能を実現している。一方で、歌声の歌詞認識となると、未だに認識精度が低いのが現状である。音楽検索や歌唱スキル評価、映像制作などへの応用が期待されている分野ではあるが、大規模なデータセットが存在しないことや歌声に特有の特徴などが研究の発展を妨げている。音声の基本周波数が高いことや、音高、長母音といった歌声固有の特徴は、既存の認識システムを流用するだけでは捉えきれないからである [1]。先行研究では、連続する母音を発音辞書に追加する [2]、音長ごとに母音のラベル付けをする [3] など、歌声に特化した認識モデルを構築することで認識率が向上することがわかっている。しかしながら、歌詞は楽曲が制作される際にメロディーや全体の雰囲気 considering して書かれており、音程やコード進行、テンポなど音響的特徴以外にも認識に役立つと思われる音楽的要素が付随する。特に、メロディーは歌詞と 1 対 1 の関係にあり、MIDI というデータ形式によりコンピュータ上で容易に処理が可能のため、歌詞の認識に有効であると仮定される。よって本研究では、アカペラ音声から音響特徴とメロディーデータを抽出し、それらを結合して利用することで歌詞の認識性能が向上するかを実験する。

2 提案手法

アカペラ音声を入力としてその歌詞を出力する歌詞認識システムを構築する。アカペラ音声に対し、特徴抽出と Audio to MIDI 変換の 2 つの処理を行い、それらを結合し認識モデルに渡す (図 1)。

2.1 認識エンジン

認識エンジンには Julius[4] を使用する。Julius は、音響モデル、言語モデル、発音辞書の組み替えが可能な大語彙連続音声認識エンジンである。

音響モデルには DNN-HMM を採用し、独自に収集した歌唱データで学習を行う。このモデルは入力層・出力層および 7 層の隠れ層を持ち、特徴量を入力として HMM 状態を出力する。




図 1 歌詞認識システムの全体像

言語モデルに関しては、収集した歌詞データから単語 trigram モデルを学習する。言語モデルの学習には Palmkit (<https://palmkit.sourceforge.net/>) を使用する。

2.2 MIDI データの導入

MIDI (Musical Instruments Digital Interface) は電子楽器同士を接続するための世界共通のデータ規格であり、音程や音長、強弱などのデータが含まれる。近年では、オーディオデータを MIDI データに変換する Audio to MIDI システムが確立されており、本研究では歌声を MIDI データに変換する。更に、MIDI データを one-hot-vector 表現に変換し音響特徴ベクトルと結合する (図 2)。音響特徴ベクトルはフィルタバンク 40 次元およびその 1 次・2 次差分の計 120 次元であり、one-hot-vector は音域 C3 から G5 までの 32 次元となる。時刻 t における連結ベクトルを V_t とすると、 V_{t-5} から V_{t+5} の 152 次元 $\times 11$ フレームを DNN の入力とする。

2.3 性能評価

歌詞認識は発展途上の分野であり、従来の音声認識のようなベンチマークタスクは確立されていない。したがって、本研究では MIDI データの導入の有無による性能を比較する。指標には、先行研究でも多く見られた単語誤り率




図2 MIDI データと特徴量の結合

(WER: Word Error Rate)

$$WER = \frac{\text{挿入単語数} + \text{置換単語数} + \text{削除単語数}}{\text{正解単語数}}$$

を用いる。

3 データベース

研究用に公開されている日本語歌唱データベースには RWC Music Database[5] などがあるが、いずれのデータベースも少量かつ古い楽曲で構成されているものが多く、現代の多様な楽曲の歌詞認識には適さない。そこで本研究では YouTube にアップロードされている楽曲を半自動的に収集し、独自に日本語歌唱データセットを構築する。

3.1 データの収集

100 組のアーティストから総計 1000 曲、60 時間分の楽曲データと歌詞データを収集する。楽曲ジャンルは J-POP のみであり、テンポはおおよそ 120bpm から 240bpm である。男性女性比はおおよそ 1 対 1 であり、あるアーティストの楽曲を他の歌唱者がカバーしたものも含まれている。複数人ユニットの楽曲や合成音声を使用した楽曲は含まれていない。また歌詞データについては、上記以外のものを 10 万単語以上を収集する。

3.2 データの加工

全ての楽曲データに対し、前処理として Vocal Remover (<https://github.com/tsurumeso/vocal-remover>) を使用し歌唱音声のみを抽出し、任意の小節毎に分割する。その際学習に適さないと思われる箇所を除外する。例えば、ラップ調、オートチューンなどの過度な加工がされている、16 部音符より短い、外国語発音による歌唱、Uh-や Ah-といった歌

詞のない歌唱などである。続いて、Julius の音素セグメンテーションキットを使用し、歌唱データに対して正解歌詞をラベリングする。

4 おわりに

本研究では、歌詞認識の新たなアプローチとして MIDI データを活用した音楽的要素の導入を試みる。音程や音長の情報を音響特徴量と結びつけることは、第 1 節で述べた歌詞認識における課題に有効であると思われる。更に、MIDI データは実質電子的な楽譜であるため、発音タイミングの整列などにも有効と思われる。

現在は、データ収集および加工のためのプログラム作成と、本実験で利用する既存システムを試用している段階であり、すべて Python で実装ができる目処が立っている。今後はデータ収集とシステムの構築に取り掛かる。Julius を基礎として実装を進めていくが、MIDI データが入力される音響モデルにおいては、ネットワークの素子数やデータの収集具合に応じた学習方法の検討が必要である。先行研究の多くは、従来の学習済み音声認識モデルに対し歌唱データでファインチューニングを行っていたが、最近では End-to-End モデルの普及やインターネットからデータを容易に収集できるようになったことで、独自にモデルを学習する研究例も増えている。また、MIDI には本文で述べた以外にも様々なデータが保持されているため、研究の進捗によっては新たな要素の導入を検討したい。MIDI データの処理については音楽生成の分野が非常に参考になるため、引き続きリサーチを進めていき音楽分析に役立てたい。

参考文献

- [1] 尾関弘尚, 鎌田貴幸, 後藤真孝, 速水悟, "歌声の歌詞認識における音高の影響について," JST さきがけ研究 21.
- [2] 川井大陸, 山本一公, 中川聖一, "朗読音声-歌声音声の特徴量変換と話者適応を用いた歌詞認識の性能向上の検討," 情報処理学会研究報告, Vol.SLP-104, No.2, 2014.
- [3] 栗田渉平, 酒向慎司, 北村正, "音長を考慮した音響モデルによる歌声の自動歌詞認識," 電子情報通信学会, ISS-SP-221, 2016.
- [4] A. Lee and T. Kawahara: Julius v4.5 (2019) <https://doi.org/10.5281/zenodo.2530395>
- [5] 後藤真孝, 橋口博樹, 西村拓一, 岡隆一, "RWC 研究用音楽データベース: 研究目的で利用可能な著作権処理済み楽曲・楽器音データベース," 情報処理学会論文誌, Vol.45, No.3, pp.728-738, 2004.