

カジュアルなシングルチャネル日本語会話音声の 話者ダイアライゼーションと文字起こし

発表者: I 類 メディア情報学 プログラム 学籍番号 2210426 土屋 楓太
指導教員: 高木 一幸 助教

1 はじめに

複数話者の混合音声認識 (Multi-Speaker Automatic Speech Recognition: MS-ASR) は、単一話者の孤立発話音声認識と比較して難易度が高いだけでなく、会議の議事録作成、インタビューの文字起こし、動画編集時の字幕付与といった作業の自動化に応用可能な重要タスクである。これを実現するためには、「誰が、いつ、何を発話したか」を推定することが必要であるが、一口に混合音声といえどもその実態によって推定の難易度は異なる。正しく音声認識できるように、混合音声を話者ごとあるいは発話ごとの音声に分離して音声認識することを考える。このとき、例えば記者会見のようなフォーマルな会話音声の場合は、複数話者が同時に発話する時間は短く、話者および発話の分離は容易である。一方、友人同士などのカジュアルなシチュエーションでの会話の場合は、あいづちや笑い声などにより頻繁に話者交代や重複発話が発生し、話者ごとに発話の分離を行うことがより困難になる。MS-ASR の要素技術の一つとして、話者ダイアライゼーションがある。これは、日常会話などの複数話者の発話からなる音声から、「誰が、いつ発話したか」を推定する技術であり、近年盛んにコンペティションが開催されているテーマでもある [1, 2]。これらのコンペティションで使用されるデータは「遠隔マイク音声 + 各話者の近接マイク音声」のようなマルチチャネルのデータが多く、空間的情報を活用して推定を行う手法が主流である。この場合、音源分離問題は信号処理問題として解くことができ、話者ごとに音声を分離して認識処理に渡すことが比較的容易である。一方、ラジオやポッドキャストの音声は、各話者の近接マイク音声ミックスされたシングルチャネルの音声であり、空間的情報が使えないため、時間周波数領域での音源分離が必要になる。

MS-ASR における別のアプローチとして、全話者の発話を時系列順に 1 つの文字列で出力する方法がある。これを出力のシリアル化という。TOGGL[3] は、トークンレベルで出力がシリアル化された単一デコーダの End-to-End (E2E) 混合音声認識モデルで、話者交代を意味する

[NEXT], [PREV] という 2 つの特殊なトークンを使用することにより複数話者の同時発話を話者ごとに文字起こしすることを可能にしている。エンコーダの学習には Cocktail HuBERT[4] の自己教師あり事前学習アプローチが使われており、話者数に対応する複数個のヘッドを使用することで、重複発話の各発話に対応する音響特徴ベクトルの予測が可能になる。このモデルは音源分離をせずとも混合音声の話者ごとの文字起こしが可能である一方、ダイアライゼーションを使用した場合のような発話の正確なタイムスタンプが出力されないという欠点がある。

Lin ら [5] は、この欠点を解決するダイアライゼーションベースの多話者シングルチャネル音声認識システムを提案した。バックエンドに大規模言語モデル (LLM) を使用しているのが特徴で、入力音声の意味埋め込み表現と話者埋め込み表現、ダイアライゼーション結果の 3 つ組 (話者埋め込み, セグメントの開始時刻, 終了時刻) を LLM に入力として与え、タイムスタンプ付きの文字起こしを出力するよう学習を行う。これは Semi-E2E と呼ばれる手法の一種で、音声の埋め込みと LLM での処理は E2E のフレームワークであるものの、入力に必要なダイアライゼーション結果は別のモジュールに依存している。

これらの先行研究を踏まえ、特に解決したい問題設定である「ラジオやポッドキャストのようなカジュアルなシングルチャネル日本語会話音声の話者ダイアライゼーションと文字起こし」の実用的精度での実現については、話者ダイアライゼーションの精度向上と重複発話の検出が重要であると考えた。そのため、本研究では、ダイアライゼーションと音源分離を中心としたパイプライン型のシステムを採用する。ダイアライゼーション精度向上のために話者数推定器をダイアライザーの前段に組み合わせること、ダイアライゼーション結果から重複発話の有無で区間を分け異なる処理を行うことで、シングルチャネル会話音声の高精度な話者ごとの文字起こしの実現を目指す。

2 提案手法

シングルチャネル会話音声を入力とし、「発話の開始・終了時間、話者 ID、発話内容」の組を発話の数だけ出力するシステムを提案する。システムは話者数推定器、ダイアライザー、音源分離器、音声認識器の4つのモジュールで構成されており、話者数推定器の出力をダイアライザーに渡し、ダイアライザーの出力から判断して重複発話がない区間はそのまま音声認識器に渡し、重複発話がある区間は音源分離器によって個々の発話に分離したのち音声認識器に渡す。ダイアライザー、音源分離器、音声認識器は既存のモデルを使用し、話者数推定器は事前学習済みモデルに追加で学習を行い実装する。以下に詳細を示す。

2.1 話者数推定器

話者数推定器には Conformer[6] を使用する。Conformer は Transformer[7] を畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) で拡張したアーキテクチャで、Transformer が得意とする長期依存関係と CNN が得意とする局所的な特徴の両方を捉えることに長ける。

2.2 ダイアライザー

ダイアライザーには pyannote.audio[8] の公開モデル speaker-diarization-3.1 を使用する。pyannote.audio は話者ダイアライゼーション用のオープンソースツールキットである。音声区間検出、話者埋め込み、重複発話検出などを組み合わせたパイプライン型のシステムで、シングルチャネル音声に対してもダイアライゼーションが可能である。

2.3 音源分離器

音源分離器は speechbrain[9] の公開モデル sepformer-libli3mix を使用する。speechbrain は音声処理用のオープンソースツールキットである。SepFormer[10] は Transformer ベースの音声分離アーキテクチャである。

2.4 音声認識器

音声認識器には WhisperX[11] を使用する。WhisperX は、OpenAI による音声認識モデル Whisper[12] の拡張版で、音素モデルによって強制アライメントすることにより、認識結果に対して単語レベルでのタイムスタンプが生成できる。

3 データセット

話者数推定器の学習及び評価のため、ポッドキャスト音声を 200 時間程度収集し、話者数ラベルを付与する。収集対象は、YouTube 上にアップロードされている話者が 2 人以上の日本語 WEB ラジオ番組とする。また、システム全

体の評価のため、日本語話し言葉コーパス (CSJ) [13] の課題指向対話及び自由対話のトラック計 6.7 時間を使用する。

4 おわりに

本研究では、パイプライン型フレームワークを使用したカジュアルなシングルチャネル日本語会話音声の話者ごとのタイムスタンプ付き文字起こしを試みる。

今後検討すべき事項として、話者数推定器に使用する事前学習済みモデルの選定がある。さらに、システム評価用データの不足が考えられるため、CSJ に加えて使用するラベル付き日本語会話コーパスを選定する。また、パイプライン型のシステムの欠点として、あるモジュールで発生した誤りが後段のモジュールに伝播しうることがあげられるため、Lin ら [5] のような Semi-E2E のシステムと比較して、どちらを採用すべきか検討したい。提案手法では重複発話検出の結果を他モジュールへの接続に利用することを想定してダイアライザーに pyannote.audio を採用しているが、他モジュールが Transformer ベースのモデルであるため、ダイアライザーも Transformer ベースのモデルに変更して E2E システムとして再設計することも視野に入る。

参考文献

- [1] Samuele Cornell, et al. The CHiME-8 DASR challenge for generalizable and array agnostic distant automatic speech recognition and diarization, 2024.
- [2] Shareef Babu Kalluri, et al. The second DISPLACE challenge : Diarization of speaker and language in conversational environments, 2024.
- [3] Chak-Fai Li, et al. TOGGL: Transcribing overlapping speech with staggered labeling, 2024.
- [4] Maryam Fazel-Zarandi, et al. Cocktail HuBERT: Generalized self-supervised pre-training for mixture and single-source speech, 2023.
- [5] Yuke Lin, et al. Diarization-aware multi-speaker automatic speech recognition via large language models, 2025.
- [6] Anmol Gulati, et al. Conformer: Convolution-augmented transformer for speech recognition, 2020.
- [7] Ashish Vaswani, et al. Attention is all you need, 2017.
- [8] Hervé Bredin, et al. Pyannote.audio: Neural building blocks for speaker diarization. In ICASSP 2020, pp. 7124–7128, 2020.
- [9] Mirco Ravanelli, et al. Speechbrain: A general-purpose speech toolkit, 2021.
- [10] Cem Subakan, et al. Attention is all you need in speech separation, 2020.
- [11] Max Bain, et al. WhisperX: Time-accurate speech transcription of long-form audio, 2023.
- [12] Alec Radford, et al. Robust speech recognition via large-scale weak supervision, 2022.
- [13] 国立国語研究所. 日本語話し言葉コーパスの構築法. 国立国語研究所, 2006.